Evaluación de Propuesta de TFE

Inducción de razonamiento en LLMs mediante PPO (TRL) con recompensa verificable en matemáticas

Evaluador: Óscar Sánchez Rueda

29 de marzo de 2026

Índice

1. Resumen ejecutivo **2**

2. Puntuación desglosada **2**

3. Checklist **3**

4. Feedback detallado **3**
- 4.1. Planteamiento del problema . . . 3
- 4.2. Viabilidad técnica . . . 4
- 4.3. Completitud formal . . . 4
- 4.4. Redacción . . . 4

5. Plan de trabajo: 3 opciones **5**
- 5.1. Opción A: Alcance mínimo viable (seguro) . . . 5
- 5.2. Opción B: Alcance recomendado (equilibrado) . . . 5
- 5.3. Opción C: Alcance ambicioso (con riesgo) . . . 5

6. Próximos pasos **6**

7. Alertas **6**

1. Resumen ejecutivo

La propuesta de Sergio Martín Reizábal presenta un trabajo de **Tipo 3 (Comparativa de soluciones)**, modalidad individual, centrado en entrenar modelos de lenguaje (LLMs) mediante aprendizaje por refuerzo con PPO (Proximal Policy Optimization) para inducir comportamiento de razonamiento estructurado en problemas matemáticos. El enfoque propone que el modelo genere una salida en dos partes: razonamiento dentro de etiquetas `<think>` y respuesta final dentro de `<answer>`, evaluando automáticamente la corrección contra el ground truth.

Se trata de una propuesta **sólida y bien fundamentada**, alineada con la línea de investigación actual en RL para LLMs (DeepSeek-R1, OpenAI o1). El alumno demuestra un conocimiento notable del campo: menciona TRL, PEFT (LoRA/QLoRA), técnicas de ahorro de memoria (gradient checkpointing), y detalla la función de recompensa con precisión. Los 5 objetivos están bien definidos y el pipeline experimental es reproducible.

Como debilidades: faltan por completar varios campos del formulario (líneas de trabajo, cuestionario, título definitivo, director, estado actual). Además, la propuesta debería acotar con mayor precisión qué modelo base se usará y qué datasets concretos, ya que la viabilidad depende críticamente de los recursos de cómputo disponibles.

CALIFICACIÓN: 8.1 / 10 — APTO

2. Puntuación desglosada

Criterio	Máx	Nota	Comentario
1. Completitud formal (2 pts)			
Modalidad indicada	0.4	0.4	Individual, correcto
Título adecuado	0.4	0.4	Preciso y descriptivo
Tipo seleccionado	0.4	0.4	Tipo 3 marcado
Líneas de trabajo marcadas	0.4	0.0	No se observan
Cuestionario completado	0.4	0.0	Campos vacíos
Subtotal	*2.0*	*1.2*	
2. Calidad del planteamiento (4 pts)			
Problema bien identificado	1.0	1.0	Excelente
Solución razonable	1.0	0.9	Muy bien planteada
Novedad / originalidad	1.0	0.7	Tema actual, no original
Conocimiento previo del campo	1.0	1.0	Sobresaliente
Subtotal	*4.0*	*3.6*	
3. Viabilidad (3 pts)			
Alcance realista para 12 ECTS	1.5	1.1	Ambicioso pero factible
Datos accesibles	0.75	0.75	Datasets públicos
Tecnologías dominables	0.75	0.55	PPO es complejo
Subtotal	*3.0*	*2.4*	
4. Redacción y presentación (1 pt)			
Claridad expositiva	0.5	0.5	Clara y fluida
Estructura coherente	0.5	0.4	Bien, pero sin párrafos separados
Subtotal	*1.0*	*0.9*	
TOTAL	**10.0**	**8.1**	**APTO**

3. Checklist

- ✓ Modalidad indicada (Individual)
- ✓ Título provisional presente y descriptivo
- ✓ Tipo de trabajo seleccionado (Tipo 3 — Comparativa)
- × Líneas de trabajo marcadas
- × Cuestionario final completado (título definitivo, director, estado actual)
- ✓ Descripción y justificación del trabajo
- ✓ Objetivos e impacto definidos
- ✓ Metodología y tecnologías descritas
- × Director asignado
- × Estado actual del trabajo descrito

4. Feedback detallado

4.1. Planteamiento del problema

Aspectos positivos

- El problema está perfectamente identificado: los LLMs fallan en tareas que requieren razonamiento multi-paso, y el enfoque de "chain-of-thought" implícito mediante RL es una solución elegante y actual.
- La distinción entre prompting explícito ("piénsalo con calma") y entrenamiento con RL para inducir el comportamiento de forma intrínseca demuestra comprensión profunda del estado del arte.
- La mención de efectos no deseados del PPO (reward hacking, charlatanería, olvido de formato) indica que el alumno ha leído literatura reciente sobre RLHF y sus limitaciones.
- Los 5 objetivos son concretos, medibles y cubren todo el pipeline: definición del problema, baselines, entrenamiento, comparación y reproducibilidad.

Sugerencias de mejora

- El tema está muy alineado con DeepSeek-R1 / GRPO (enero 2025). Conviene **citar explícitamente** este trabajo y posicionarse: ¿se replica su enfoque? ¿se mejora? ¿se aplica a modelos más pequeños? Esto clarificaría la contribución original.
- La propuesta no especifica **qué modelo base** se usará. La elección (Llama 3, Mistral, Qwen, Phi...) condiciona enormemente la viabilidad (VRAM necesaria, licencia, tokenizer).
- No se mencionan **datasets concretos**. Para matemáticas con ground truth hay opciones clásicas (GSM8K, MATH, SVAMP, AQuA), pero conviene indicar cuál(es) se usarán y justificar la elección.
- La propuesta menciona PPO pero no discute alternativas como **GRPO o DPO** que podrían ser más estables y menos costosas computacionalmente. Incluir al menos una mención comparativa reforzaría el marco teórico.

4.2. Viabilidad técnica

Aspectos positivos

- El uso de TRL + PEFT (LoRA/QLoRA) con técnicas de ahorro de memoria (gradient checkpointing, batch pequeño, acumulación de gradientes) indica que el alumno es consciente de las limitaciones de hardware.
- La función de recompensa está bien diseñada: +1.0 por respuesta correcta, +0.05 por formato válido, penalización por verbosidad. Es verificable y automatizable.
- Los baselines propuestos (prompting directo vs. prompting con formato `<think>/<answer>`) son adecuados y permiten aislar el efecto del entrenamiento RL.
- La métrica de evaluación (match normalizado con tolerancia numérica) es práctica y estándar en la literatura de razonamiento matemático.

Aspectos críticos

- **Recursos de cómputo no especificados.** Entrenar con PPO requiere mantener 4 copias del modelo en memoria (policy, reference, value head, reward). Incluso con LoRA y un modelo de 7B, se necesitan mínimo 24 GB de VRAM (A10G o superior). ¿El alumno tiene acceso a GPU adecuada? ¿Usará Google Colab Pro, un clúster universitario, o recursos propios? Este punto es **crítico** para la viabilidad.
- **Tiempo de entrenamiento.** Un run de PPO con LoRA sobre un modelo 7B puede tardar 12–48 horas en una A100. Si se necesitan múltiples runs para ajustar hiperparámetros (learning rate, KL penalty, reward shaping), el tiempo total puede ser de semanas. Hay que planificarlo.

4.3. Completitud formal

Aspectos críticos

- **Campos vacíos en el formulario:** El título definitivo, director, estado actual del trabajo y tareas pendientes están sin completar. Esto sugiere que es una primera versión del formulario y debe revisarse antes de la entrega final.
- **Líneas de trabajo no marcadas.** El formulario requiere indicar las líneas de investigación del máster a las que se adscribe el trabajo.
- **Cuestionario sin completar.** La sección final del formulario (cambio de director, etc.) tiene los campos vacíos.

4.4. Redacción

Aspectos positivos

- La redacción es fluida, clara y demuestra dominio del vocabulario técnico (PPO, TRL, PEFT, reward shaping, gradient checkpointing).
- El texto está bien argumentado: plantea el problema, describe la solución, anticipa problemas y define métricas. Es una narrativa completa.
- El ejemplo concreto ("me quedan X euros" vs. "cuánto dinero queda") ilustra eficazmente el concepto de robustez ante reformulaciones.

Sugerencias de mejora

- El texto es un único bloque continuo sin separación en párrafos o secciones. Aunque el formulario impone restricciones de formato, usar saltos de línea entre la descripción, los objetivos y la metodología mejoraría la legibilidad.
- Algunas frases son excesivamente largas (>50 palabras). Conviene dividirlas para facilitar la lectura del evaluador.

5. Plan de trabajo: 3 opciones

5.1. Opción A: Alcance mínimo viable (seguro)

1. Seleccionar **un solo modelo base** pequeño (Phi-3-mini 3.8B o Qwen2.5-3B) y **un solo dataset** (GSM8K, ∼7.5K problemas de primaria/secundaria).
2. Implementar los 2 baselines de prompting (directo y formato `<think>/<answer>`).
3. Entrenar con PPO + LoRA usando TRL, un único run con hiperparámetros de referencia de la documentación de TRL.
4. Comparar accuracy pre/post entrenamiento + robustez ante reformulaciones (10 problemas reformulados manualmente).
5. Documentar pipeline completo con scripts reproducibles.

Duración estimada: 8–10 semanas. **Riesgo:** bajo.

5.2. Opción B: Alcance recomendado (equilibrado)

Todo lo de la Opción A, más:

6. Añadir un **segundo modelo base** (7B parámetros: Llama 3.1 7B o Mistral 7B) para comparar el efecto del tamaño.
7. Añadir un **segundo dataset** (MATH, más difícil) para evaluar generalización.
8. Comparar PPO con al menos **un método alternativo** (GRPO o DPO) para contextualizar los resultados.
9. Análisis cuantitativo de costes: tiempo de entrenamiento, tokens generados, VRAM consumida.
10. Estudio de errores: clasificar los fallos del modelo (cálculo, formato, hallucination).

Duración estimada: 12–14 semanas. **Riesgo:** medio (requiere GPU potente).

5.3. Opción C: Alcance ambicioso (con riesgo)

Todo lo de la Opción B, más:

11. Implementar **GRPO completo** (sin modelo crítico separado) como alternativa a PPO y comparar estabilidad/coste.
12. Evaluar en **3+ datasets** incluyendo dominios fuera de matemáticas (lógica, código) para probar transferencia.
13. Ablation study: variar componentes de la recompensa (peso del formato, penalización de longitud) y medir impacto.
14. Publicar el modelo entrenado en HuggingFace Hub con model card completa.

Duración estimada: 16–20 semanas. **Riesgo:** alto (recursos, tiempo, complejidad experimental).

Recomendación: La **Opción B** es la más adecuada para un TFE de 12 ECTS. Ofrece profundidad suficiente para una comparativa rigurosa sin depender de recursos de cómputo excepcionales.

6. Próximos pasos

1. **Completar el formulario:** Rellenar los campos vacíos (líneas de trabajo, cuestionario, director, estado actual). Es imprescindible antes de la entrega formal.

2. **Especificar modelo base y dataset:** Elegir el modelo concreto (recomendación: empezar con Qwen2.5-3B por eficiencia) y el dataset principal (recomendación: GSM8K como punto de partida).

3. **Verificar acceso a GPU:** Confirmar disponibilidad de al menos una GPU con 24 GB VRAM (A10G, L4, A100). Opciones: Google Colab Pro+ (∼50€/mes), Lambda Cloud, o clúster universitario.

4. **Posicionarse frente a DeepSeek-R1:** Leer el paper de DeepSeek-R1 (enero 2025) y explicitar en la propuesta cómo se diferencia o complementa este trabajo.

5. **Crear repositorio con estructura inicial:** Carpetas para scripts de entrenamiento, evaluación, datos, y notebooks de análisis. Esto demuestra al tribunal que el pipeline es reproducible desde el principio.

6. **Hacer un *smoke test* temprano:** Antes de escribir el marco teórico, ejecutar un mini-entrenamiento PPO con TRL sobre un modelo pequeño (1–3B) durante 50–100 steps para verificar que el pipeline funciona end-to-end.

7. Alertas

Aspectos críticos

- **ALERTA 1 — Recursos de cómputo:** El entrenamiento con PPO es significativamente más costoso que el fine-tuning supervisado. Sin acceso confirmado a GPU adecuada, el proyecto no es viable. **Acción:** confirmar recursos antes de aprobar la propuesta.

- **ALERTA 2 — Formulario incompleto:** Cuatro campos obligatorios están vacíos. **Acción:** el alumno debe reenviar el formulario completo.

- **ALERTA 3 — Originalidad vs. replicación:** El enfoque de "entrenar LLMs con RL para razonamiento matemático" ha sido publicado recientemente por DeepSeek (GRPO), Microsoft (rStar), y otros. El alumno debe argumentar explícitamente qué aporta su trabajo más allá de replicar estos resultados con otros modelos/datos. Sin esta diferenciación, un tribunal podría cuestionar la contribución.

- **ALERTA 4 — Estabilidad del PPO:** El entrenamiento PPO en LLMs es notoriamente inestable (reward hacking, mode collapse, KL divergence explosion). El alumno lo menciona brevemente, pero debe estar preparado para dedicar tiempo significativo a depuración y ajuste de hiperparámetros. **Recomendación:** considerar GRPO como alternativa más estable si PPO resulta problemático.